

Segmentación automática de columna vertebral y vértebras en radiografías con escoliosis para entornos con recursos computacionales limitados.

Katherine Camacho Celis, Juan Sebastian Parada Celis
Jorge Esteban Clavijo Sanchez, Juan Sebastian Madrid Palencia
Maestría en Inteligencia Artificial (MAIA)
Universidad de los Andes, Bogotá, Colombia
k.camachoc2@uniandes.edu.co, j.paradac@uniandes.edu.co
je.clavijos1@uniandes.edu.co, j.madridp@uniandes.edu.co

Abstract—La escoliosis es una deformidad estructural de la columna vertebral cuyo análisis radiográfico exige identificar con precisión la columna completa y cada vértebra individual. La segmentación manual de radiografías anteroposteriores (AP) es un proceso demorado, susceptible a variabilidad inter e intraobservador y especialmente complejo en entornos clínicos con recursos computacionales limitados. En este contexto, este trabajo muestra el desarrollo y la evaluación de un sistema de segmentación automática de columna vertebral y vértebras T1–L5, empleando modelos ligeros de aprendizaje profundo orientados a la ejecución eficiente en CPU.

Se utilizó un conjunto de 185 radiografías AP con escoliosis, depurado y re-annotado para generar 17 clases vertebrales anatómicamente coherentes. Sobre este dataset se compararon tres arquitecturas representativas: U-Net para segmentación semántica, Mask R-CNN para segmentación de instancias y variantes de YOLOv8-seg como enfoque de una sola etapa. La evaluación consideró métricas de segmentación (IoU, coeficiente Dice), desempeño de detección (mAP) y eficiencia computacional (tamaño del modelo y tiempo de inferencia).

Los resultados obtenidos muestran diferencias claras en precisión, nivel de detalle anatómico alcanzado y costo computacional entre las arquitecturas evaluadas. Estos hallazgos evidencian la utilidad de los modelos ligeros para tareas de segmentación vertebral en contextos con recursos limitados, y permiten sentar las bases para seleccionar y ajustar el modelo final para su uso en análisis radiográficos automatizados.

Index Terms—Escoliosis, segmentación vertebral, imágenes radiográficas, aprendizaje profundo, YOLOv8, Mask R-CNN, U-Net.

I. INTRODUCCIÓN

La escoliosis es una deformidad estructural de la columna vertebral caracterizada por curvaturas laterales y rotación vertebral, cuyo diagnóstico y seguimiento dependen de la interpretación cuidadosa de radiografías anteroposteriores (AP). En la práctica clínica actual, la identificación de la columna completa y de cada vértebra individual continúa realizándose de forma manual, lo que demanda tiempo, introduce variabilidad entre especialistas y dificulta la estandarización de evaluaciones, con discrepancias que pueden alcanzar entre 4° y 8° en la medición del ángulo de Cobb [1]. Esta situación resalta la necesidad de desarrollar herramientas automáticas

que apoyen la lectura radiográfica y contribuyan a mejorar la consistencia diagnóstica.

El avance de técnicas de visión por computador y aprendizaje profundo ha permitido mejoras significativas en la segmentación de estructuras anatómicas. Modelos como U-Net han demostrado buen desempeño en segmentación semántica [2], mientras que arquitecturas como Mask R-CNN permiten distinguir objetos individuales dentro de una misma región anatómica [3]. Más recientemente, métodos de una sola etapa como YOLOv8-seg, que integran detección y segmentación en un único paso, han mostrado un balance favorable entre precisión y eficiencia, abriendo la puerta a implementaciones en CPU sin requerir hardware especializado [4].

Sin embargo, persisten brechas importantes: la mayoría de trabajos previos se enfocan en anatomías sin deformidades, en vistas laterales o en la segmentación de la columna como una única región continua [5]. Adicionalmente, múltiples estudios reportan que las vértebras lumbares inferiores —especialmente L4 y L5— presentan mayores dificultades de segmentación debido al bajo contraste y la superposición pélvica [6], [7]. Por otro lado, la mayor parte de los modelos publicados asume disponibilidad de GPU, lo que limita su aplicabilidad en centros asistenciales con infraestructura reducida [3]. Estas limitaciones justifican la necesidad de explorar modelos livianos que permitan segmentar vértebras individuales en escenarios clínicos reales.

En este contexto, el objetivo de este trabajo es desarrollar y evaluar un sistema automático de segmentación de la columna vertebral y de las vértebras T1–L5 en radiografías AP con escoliosis, utilizando modelos ligeros de aprendizaje profundo optimizados para ejecución en CPU. Para cumplir este objetivo, se depuró y preprocesó un conjunto de datos clínico, se entrenaron y compararon tres arquitecturas representativas (U-Net, Mask R-CNN y variantes de YOLOv8-seg) y se evaluó su precisión y eficiencia computacional bajo un mismo protocolo experimental.

Este artículo presenta la revisión del estado del arte en segmentación vertebral, la metodología utilizada, los resultados obtenidos y la discusión de los hallazgos principales.

II. ESTADO DEL ARTE

El análisis radiográfico de la escoliosis se ha basado históricamente en radiografías anteroposteriores (AP/PA) y en la medición manual del ángulo de Cobb, procedimiento que presenta una variabilidad inter e intraobservador ampliamente documentada [8], [1]. La selección de las vértebras límite, el bajo contraste en zonas torácicas profundas y la superposición de estructuras pélvicas introducen discrepancias que pueden oscilar entre 4° y 8° [8], lo que resalta la necesidad de métodos más reproducibles y menos dependientes del operador.

En la última década, el análisis automático de la columna ha incorporado enfoques de aprendizaje profundo, los cuales pueden agruparse en tres líneas principales. Primero, los métodos de *regresión directa* de puntos anatómicos o ángulos, como S2VR y BoostNet [9], así como los modelos basados en puntos clave para medición automatizada del ángulo de Cobb [10]. Aunque estos métodos modelan la estructura global, requieren fuertes reducciones de resolución y altos recursos computacionales.

Segundo, los métodos de *segmentación semántica e instancia*, entre los cuales destacan U-Net [11], [2] y Mask R-CNN [12], [3]. Estos enfoques permiten delinear la columna o identificar vértebras específicas, aunque típicamente dependen de hardware con GPU para alcanzar tiempos de inferencia razonables.

Tercero, los métodos basados en *detección de objetos con regresión de puntos clave*, como Faster R-CNN [13] o variantes aplicadas a radiografías espinales [5], los cuales han reportado errores porcentuales SMAPE entre 15.9% y 25.7% en conjuntos superiores a 600 radiografías—métrica que evalúa el error porcentual de forma simétrica respecto al valor real y al predicho.

Dentro de esta línea, Chen et al. presentaron un enfoque basado en YOLACT para segmentación de vértebras en radiografías AP, obteniendo un SMAPE de 10.76% y cerca del 95% de predicciones con errores menores a 10° respecto al trazado manual [14]. Este resultado confirma que los métodos *one-stage* pueden lograr precisión clínica con costos computacionales moderados.

No obstante, múltiples trabajos coinciden en que las vértebras lumbares inferiores—especialmente L5—presentan las métricas más bajas debido al bajo contraste, la superposición con la pelvis y la variabilidad anatómica [6], [7], [15]. Esta tendencia persiste incluso en modelos avanzados, y sigue siendo uno de los principales desafíos en la segmentación automatizada de la columna.

Adicionalmente, gran parte de las investigaciones existentes se enfocan en anatomías sin deformidades severas, vistas laterales o segmentación de la columna como una región continua [5]. Asimismo, la mayoría de los modelos asume ejecución sobre GPU, lo que limita su aplicabilidad en centros asistenciales con recursos computacionales restringidos.

Estas brechas motivan el presente trabajo, orientado a analizar y comparar arquitecturas ligeras—principalmente variantes de YOLOv8-seg—capaces de segmentar vértebra

por vértebra en radiografías AP con escoliosis, optimizando tiempos de inferencia y precisión anatómica para ejecución eficiente en CPU.

III. METODOLOGÍA

La metodología aplicada en este proyecto comprende todas las etapas necesarias para el desarrollo de un sistema de segmentación automática de columna vertebral en radiografías AP con identificación de cada vértebra, abarcando desde la preparación del conjunto de datos hasta el entrenamiento, evaluación y despliegue del modelo. En esta sección se describen detalladamente cada una de estas fases y, finalmente, se expone la estrategia de despliegue utilizada para evaluar la viabilidad operativa del sistema en escenarios con recursos computacionales restringidos.

A. Dataset

Los datos utilizados en este proyecto corresponden a un conjunto de 185 radiografías anteroposteriores (AP) de columna vertebral, acompañadas de archivos de máscara y un archivo de anotaciones en formato COCO JSON, estructurado bajo las claves `images`, `categories` y `annotations`. Estas imágenes fueron obtenidas y anotadas por una institución médica en convenio con la Universidad de los Andes, lo que garantiza la calidad y procedencia clínica del material. La estructura del dataset es coherente con otros trabajos recientes de segmentación de columna que utilizan formatos derivados de COCO o similares [2].

Las anotaciones iniciales incluían tres clases: columna vertebral (V), primera vértebra torácica (T1) y fondo (F). A partir de esta estructura se construyó el conjunto de datos de referencia sobre el cual se realizaron las etapas posteriores de depuración, enriquecimiento de anotaciones y entrenamiento de las arquitecturas de segmentación evaluadas.

B. Recolección y preparación de datos

El análisis preliminar del dataset reveló inconsistencias en las anotaciones: 7 imágenes sin anotaciones, 10 con anotaciones incompletas y el resto con las tres etiquetas esperadas. Como parte del preprocesamiento inicial, se descartaron las imágenes sin anotaciones y aquellas correspondientes a pacientes sin escoliosis, identificadas mediante el prefijo `N_` en el nombre del archivo dentro del JSON.

Posteriormente, se llevó a cabo un proceso de depuración y enriquecimiento de anotaciones para obtener una segmentación más precisa por vértebra. A partir de las anotaciones existentes de T1 y V, se calculó el centroide de T1 y los centroides de todas las regiones vertebrales presentes en la máscara de V. Luego, se identificó la vértebra más cercana a T1 dentro de la anotación de la columna y, tomando esta como referencia, se asignaron etiquetas progresivas de T1 a L5, siguiendo el orden anatómico descendente. Este procedimiento está alineado con técnicas previas de identificación vertebral basadas en distancias geométricas y estructuras ordinales [15].

Para ilustrar este proceso de depuración y enriquecimiento de anotaciones, la Figura 1 muestra una comparación entre

las máscaras originales del dataset y las nuevas etiquetas generadas automáticamente para cada vértebra individual. Esta transformación fue crucial para habilitar el entrenamiento de modelos de segmentación por instancias y constituye uno de los aportes principales de la fase de preparación de datos.




Fig. 1. Comparación entre las anotaciones originales (izquierda) y el esquema de etiquetas enriquecidas por vértebra (derecha), generado durante la fase de preparación del dataset.

Las nuevas anotaciones fueron incorporadas al archivo COCO final y verificadas visualmente mediante la superposición de las máscaras sobre las radiografías originales, garantizando la coherencia geométrica y la continuidad anatómica entre vértebras. En este proceso también se generaron subconjuntos para entrenamiento y validación, manteniendo una distribución equilibrada de casos y asegurando la diversidad de patrones de curvatura, práctica consistente con estudios recientes [7].

Cabe resaltar que no todas las imágenes fueron descartadas para todas las arquitecturas consideradas. Algunas radiografías con anotaciones parciales se conservaron para el entrenamiento de modelos como U-Net, cuyo enfoque semántico permitía aprovecharlas de forma útil. En cambio, para modelos de segmentación por instancias como YOLOv8-seg y Mask R-CNN, se trabajó exclusivamente con las imágenes que contaban con todas las vértebras correctamente identificadas y categorizadas, coherente con los requisitos de segmentación por instancia reportados en la literatura [3].

El resultado de este proceso de preparación fue un conjunto de datos depurado, estructurado y validado, que sirvió como base para la comparación de las tres arquitecturas evaluadas, asegurando consistencia en las etiquetas, balance entre clases y trazabilidad completa de las anotaciones.

C. Preprocesamiento

El preprocesamiento incluyó tanto la preparación geométrica e intensidad de las imágenes como la depuración final del conjunto de datos según los requerimientos de cada

arquitectura. Debido a que YOLOv8-seg y Mask R-CNN realizan segmentación por instancias, solo fue posible utilizar radiografías con la columna completa y con las 17 vértebras correctamente anotadas. El subconjunto resultante para estos modelos incluyó 134 imágenes para entrenamiento y 34 para validación, luego de descartar casos con anotaciones incompletas o vértebras ausentes.

En contraste, U-Net, al tratarse de una arquitectura de segmentación semántica, permitió emplear imágenes con anotaciones parciales y aquellas en las que la columna estaba segmentada como una única región continua. Este enfoque ha sido utilizado previamente en segmentación espinal cuando la prioridad es preservar la morfología global [2].

Además de la depuración por arquitectura, se aplicaron transformaciones estándar de preprocesamiento. Para YOLOv8-seg se utilizaron resoluciones de entrada de 1024 y posteriormente 1280 píxeles, junto con normalización automática dentro del pipeline del modelo. En Mask R-CNN se empleó el preprocesamiento integrado de Detectron2/MMD, que realiza redimensionamiento, normalización y centrado de las imágenes. Para U-Net se ajustaron resoluciones entre 512 y 1024 píxeles según la capacidad del modelo, siguiendo criterios utilizados en trabajos previos de segmentación biomédica [11].

Finalmente, se incorporaron técnicas de aumentación de datos de acuerdo con las capacidades de cada arquitectura. En YOLOv8-seg se emplearon exclusivamente las aumentaciones internas del pipeline de Ultralytics, tales como *horizontal flip* (0.5), rotaciones de hasta 8° y escalamientos leves, ya que el modelo no permite aplicar aumentaciones externas sin modificar su dataloader. En Mask R-CNN no se realizaron aumentaciones manuales; se utilizaron únicamente las transformaciones estándar del framework (redimensionamiento dinámico, normalización y, cuando aplicaba, *horizontal flip*). Para U-Net sí se aplicaron aumentaciones explícitas sobre imágenes y máscaras —incluyendo *horizontal flip*, rotaciones suaves y escalamientos moderados— con el fin de mejorar la capacidad de generalización del modelo, estrategia documentada también en segmentación espinal [5].

D. Modelos evaluados

El proceso de modelado se basó en el entrenamiento supervisado de redes neuronales convolucionales (CNNs) utilizando el conjunto de datos depurado. Con el fin de comparar enfoques semánticos, de dos etapas y de una sola etapa, se evaluaron tres arquitecturas representativas: U-Net, Mask R-CNN y YOLOv8-seg. Estas arquitecturas permiten contrastar precisión anatómica, capacidad de generalización y eficiencia computacional, criterios esenciales para su despliegue en CPU en entornos clínicos con recursos limitados.

Aunque comparten una base convolucional, cada arquitectura aborda la segmentación desde un paradigma distinto: U-Net genera una máscara semántica continua de la columna [11], Mask R-CNN implementa un flujo *two-stage* que detecta regiones de interés y produce una máscara por vértebra [12], mientras que YOLOv8-seg aplica un enfoque *one-stage* que

integra detección y segmentación en un único paso, siguiendo el principio de modelos YOLO aplicados previamente a la columna [4]. Todas las arquitecturas fueron inicializadas desde pesos preentrenados (ImageNet o COCO), lo cual aceleró la convergencia y mejoró su capacidad de generalización.

1) *U-Net*: U-Net se empleó como línea base de segmentación semántica. Su estructura encoder-decoder con conexiones de salto permite combinar contexto global con detalles locales. En este trabajo se utilizaron dos variantes: una versión base con backbone ResNet-34 y una versión U-Net++ con topología anidada que refina la propagación de características. Ambas arquitecturas se entrenaron con imágenes completas o parcialmente anotadas, ampliando así su conjunto de entrenamiento en comparación con los modelos de segmentación por instancias, estrategia también utilizada en otros estudios similares [2].

2) *Mask R-CNN*: Mask R-CNN se implementó mediante MMDetection/Detectron2 utilizando un backbone ResNet-50 con Feature Pyramid Network (FPN). El modelo opera en dos etapas: un *Region Proposal Network* identifica regiones de interés y, posteriormente, cada región es clasificada y segmentada para generar una máscara independiente por vértebra. Este enfoque ha sido aplicado con éxito en segmentación vertebral en TC y radiografías [3]. Se utilizó un checkpoint preentrenado en COCO y se adaptó la arquitectura a las 17 clases correspondientes a T1–T12 y L1–L5.

3) *YOLOv8-seg*: YOLOv8-seg representa un enfoque *one-stage* que produce simultáneamente *bounding boxes*, clases y máscaras de segmentación en un único paso de inferencia. En este proyecto se evaluaron las variantes *Small* y *Medium*, entrenadas con 134 imágenes con anotaciones completas y validadas con 34 imágenes adicionales. Se experimentó con resoluciones de entrada de 1024 y 1280 píxeles, con el fin de analizar el compromiso entre precisión, tiempo de inferencia y tamaño del modelo. El uso de modelos YOLO en anatomía espinal ha demostrado ser viable en estudios recientes [4].

E. Entrenamiento

El entrenamiento de los modelos se realizó mediante aprendizaje supervisado utilizando el conjunto de datos depurado y dividido en subconjuntos de entrenamiento y validación. Todas las redes se entrenaron en GPU mediante Google Colab para acelerar la convergencia y permitir experimentación iterativa con diferentes configuraciones.

U-Net y U-Net++ se entrenaron sobre un conjunto ampliado de imágenes, incluyendo casos con anotaciones parciales. Ambas variantes emplearon una función de pérdida basada en Binary Cross-Entropy y Dice Loss, el optimizador Adam y un número de épocas determinado según el comportamiento del conjunto de validación.

Mask R-CNN se entrenó mediante Detectron2/MMDetection utilizando un backbone ResNet-50 con Feature Pyramid Network (FPN) inicializado desde un checkpoint preentrenado en COCO. Este enfoque y configuración son consistentes con implementaciones previas en segmentación espinal [3]. El modelo empleó el optimizador

SGD con momento, pérdidas combinadas para clasificación, regresión y máscaras, y un esquema de *learning rate warmup*.

YOLOv8-seg se entrenó utilizando la librería Ultralytics en sus variantes *Small* y *Medium*. Los modelos se entrenaron con resoluciones de entrada de 1024 y 1280 píxeles para analizar el compromiso entre precisión y costo computacional, siguiendo recomendaciones similares en trabajos previos [4].

En todos los casos, el número de épocas se estableció de manera experimental observando la estabilización de las curvas de pérdida y el desempeño del conjunto de validación. Si bien el entrenamiento se llevó a cabo en GPU, la evaluación final de inferencia y eficiencia se realizó en CPU de acuerdo con los objetivos del proyecto, en línea con aplicaciones orientadas a entornos clínicos con hardware limitado [5].

F. Métricas de evaluación

La evaluación del desempeño se realizó utilizando métricas estándar en segmentación médica y segmentación por instancias, con el fin de comparar arquitecturas de distinta naturaleza bajo un protocolo común. Como criterio de calidad para este proyecto, se estableció un objetivo mínimo basado en referencias clínicas: un coeficiente Dice global de la columna mayor a 0.85 y un Dice por vértebra superior a 0.70 para las 17 clases (T1–T12 y L1–L5). Estos umbrales se encuentran alineados con valores reportados en la literatura especializada [6].

Para segmentación semántica (U-Net y U-Net++), se emplearon IoU (Intersection over Union) y el coeficiente Dice, métricas ampliamente utilizadas en segmentación biomédica [11]. IoU mide el solapamiento directo, mientras que Dice enfatiza la similitud en términos de área, siendo especialmente útil en estructuras pequeñas o con contornos complejos.

En los modelos de segmentación por instancias (YOLOv8-seg y Mask R-CNN), además de las métricas mAP₅₀ y mAP_{50–95}, se calcularon IoU y Dice por vértebra. Esto permitió comparar directamente todas las arquitecturas bajo un criterio geométrico unificado. Este enfoque es coherente con evaluaciones previas en segmentación espinal con modelos de dos etapas [3] y modelos one-stage [4].

Las métricas fueron calculadas globalmente y por clase, con el fin de evaluar la variabilidad entre regiones torácicas y lumbares. Todas las evaluaciones se realizaron sobre un conjunto de validación común, garantizando comparaciones equitativas entre las arquitecturas evaluadas.

G. Evaluación de inferencia y eficiencia computacional

Aunque el objetivo del proyecto es identificar un modelo viable para su ejecución en CPU, la evaluación de inferencia se realizó sobre GPU debido a limitaciones de disponibilidad de hardware. Sin embargo, se registraron métricas clave que permiten estimar la eficiencia computacional relativa entre arquitecturas: tiempo de inferencia por imagen, tamaño del modelo y uso de memoria. Este tipo de análisis ha sido subrayado como crítico en aplicaciones clínicas reales [5].

Los tiempos de inferencia se midieron ejecutando cada modelo repetidamente sobre el conjunto de validación y promediando el tiempo de procesamiento por imagen. Si bien estas

mediciones se obtuvieron en GPU, las diferencias observadas entre arquitecturas reflejan características estructurales que se mantienen al ejecutarse en CPU, como la profundidad del backbone, el número de parámetros o el hecho de operar en una o dos etapas.

El tamaño del modelo se consideró un indicador fundamental para su posible despliegue en sistemas con recursos limitados. Aunque la evaluación se realizó en GPU, las métricas obtenidas permiten comparar arquitecturas de manera consistente y estimar su comportamiento relativo en escenarios reales de ejecución en CPU, en línea con recomendaciones de trabajos previos sobre despliegue ligero de modelos en entornos clínicos [1].

H. Despliegue de la solución

Una vez identificado el modelo con mejor compromiso entre precisión, eficiencia y tamaño, se procedió al despliegue operativo de la solución. El objetivo de esta etapa fue evaluar la viabilidad del sistema más allá del entrenamiento, considerando su integración en un entorno real y su ejecución en hardware limitado. La importancia de validar modelos en condiciones de despliegue ha sido destacada en aplicaciones clínicas recientes [5].

Como parte del proceso de ingeniería del sistema, se incorporaron principios de MLOps orientados a garantizar reproducibilidad, trazabilidad y facilidad de actualización del modelo. Se implementó un flujo de trabajo que incluye: versionamiento automático de modelos y artefactos de entrenamiento, almacenamiento estructurado de experimentos (curvas de pérdida, métricas por época, configuraciones de hiperparámetros) y scripts de preparación para exportar el modelo a formatos ligeros adecuados para inferencia en CPU. Este enfoque permitió mantener consistencia entre las distintas fases del proyecto y facilitó la puesta en producción del modelo seleccionado.

El modelo final fue empaquetado y expuesto mediante una API REST, a través de un backend encargado de recibir la radiografía, ejecutar el preprocesamiento, realizar la inferencia y retornar las máscaras segmentadas junto con las clases asociadas a cada vértebra. Sobre este backend se desarrolló un frontend ligero que permite cargar radiografías, visualizar las predicciones y evaluar el comportamiento del sistema en tiempo real desde navegadores web o dispositivos móviles.

La solución fue probada en computadores sin GPU y en teléfonos móviles, verificando su estabilidad y capacidad de respuesta bajo condiciones de recursos restringidos. Estas pruebas permitieron estimar el comportamiento operativo del sistema en entornos clínicos donde el hardware especializado no está disponible, complementando así la evaluación cuantitativa realizada en la etapa experimental.

IV. RESULTADOS Y EVALUACIÓN

En esta sección se presentan los resultados obtenidos por las tres arquitecturas evaluadas —U-Net, Mask R-CNN y YOLOv8-seg— utilizando el conjunto de validación común definido en la metodología. El análisis considera métricas




Fig. 2. Pipeline general del sistema: desde la radiografía de entrada hasta la visualización de la segmentación en el frontend.

de segmentación (Dice, IoU), métricas de detección y segmentación por instancia (mAP_{50} , mAP_{50-95}), así como criterios de eficiencia computacional relevantes para su posterior despliegue en CPU.

A. Comparación cuantitativa entre arquitecturas

La Tabla I resume el desempeño global de cada modelo sobre una radiografía de referencia y métricas agregadas del conjunto de validación. Los modelos de la familia YOLOv8 muestran un equilibrio superior entre precisión, velocidad de inferencia y tamaño de modelo, mientras que Mask R-CNN ofrece segmentaciones de alta calidad a costa de un mayor costo computacional. U-Net, al tratarse de segmentación semántica, produce máscaras coherentes de la columna completa, pero no distingue vértebras individuales.

TABLE I
COMPARACIÓN GLOBAL DE DESEMPEÑO ENTRE MODELOS

Métrica	YOLOv8m	YOLOv8s	Mask R-CNN	U-Net
mAP_{50}	0.84	0.86	0.55	N/A
Dice	0.72	0.74	0.77	0.54
IoU	0.63	0.66	0.71	0.42
Peso [MB]	52.3	22.8	335	99.6
Inferencia [ms]	19.1	21	146	–

B. Desempeño del modelo YOLOv8-seg por vértebra

El mejor modelo obtenido (YOLOv8m-seg, 100 épocas) alcanzó una precisión sólida en la mayoría de las vértebras torácicas (T1–T12) y lumbares superiores (L1–L4). La Tabla II presenta los valores de Dice e IoU por clase. Tal como se reporta en la literatura, la vértebra L5 continúa siendo la más desafiante debido a su menor contraste, superposición con la pelvis y variabilidad anatómica.

TABLE II
MÉTRICAS POR VÉRTEBRA PARA EL MODELO YOLOV8M-SEG

Clase	Dice	IoU	Imágenes
T1–T12	0.73–0.82	0.64–0.74	32
L1–L4	0.71–0.77	0.64–0.70	32
L5	0.5195	0.4377	32
Promedio	0.7466	0.6657	32

A nivel global, el modelo alcanzó un Dice de columna de 0.9090 e IoU de 0.8339, cumpliendo los objetivos clínicos establecidos para este proyecto (Dice columna > 0.85, Dice vértebra > 0.70).

C. Optimización del modelo YOLOv8-seg

Durante la primera fase del proyecto, las métricas del modelo YOLOv8-seg fueron inferiores debido a inconsistencias detectadas en dos imágenes del conjunto de validación (ID 45 y 97), las cuales presentaban anotaciones irregulares, inclinaciones severas y características fuera de distribución. Dichas imágenes fueron excluidas únicamente del conjunto de validación tras una inspección visual con superposición GT-Pred, evitando modificar el entrenamiento.

Posteriormente, se realizaron ajustes progresivos al entrenamiento: *fine-tuning* desde el mejor checkpoint, incremento del número de épocas, reducción de la tasa de aprendizaje y eliminación de aumentaciones agresivas. Además, se implementó un pipeline propio para calcular métricas por vértebra (Dice, IoU), debido a que YOLOv8 no las reporta de manera nativa.

Estos ajustes permitieron estabilizar el desempeño del modelo y mejorar sustancialmente la precisión global. Sin embargo, los experimentos confirmaron que el modelo entrenado durante 100 épocas sigue siendo el más equilibrado: mayor precisión en torácicas, menor degradación en lumbares bajas y ausencia de sobreajuste. Aun así, la vértebra L5 permanece como la clase más difícil, lo cual es consistente con hallazgos reportados en la literatura, donde las vértebras lumbares inferiores —especialmente L5— suelen presentar las métricas más bajas debido al bajo contraste, la superposición pélvica y la mayor variabilidad anatómica [7].

D. Resultados visuales

La Figura 3 ilustra ejemplos de segmentación obtenidos por YOLOv8m-seg sobre el conjunto de validación, donde se observan máscaras bien delimitadas en la región torácica y ligera inestabilidad en L5. Estas visualizaciones fueron útiles para identificar errores sistemáticos y para validar la coherencia anatómica de las predicciones.

E. Desempeño de U-Net

U-Net logró una segmentación coherente de la columna completa, alcanzando un Dice promedio de 0.54. Sin embargo, su naturaleza semántica impide distinguir vértebras individuales, lo que limita su utilidad para mediciones automáticas o análisis clínicos que requieren identificación precisa de T1–L5. Las máscaras producidas fueron estables, pero con dificultad para diferenciar límites entre vértebras adyacentes.

F. Desempeño de Mask R-CNN

Mask R-CNN obtuvo las mejores métricas geométricas de segmentación por instancia (Dice = 0.77, IoU = 0.71). No obstante, su peso (335 MB) y su tiempo de inferencia (146 ms por imagen) lo hacen poco adecuado para entornos clínicos con recursos computacionales limitados. Además, presentó inestabilidad en la región torácica media debido al solapamiento anatómico propio de estas radiografías.




Fig. 3. Ejemplos cualitativos de segmentación vértebra por vértebra con el modelo seleccionado: radiografías S22 y S119 en vista original y con las máscaras predichas.

G. Análisis comparativo

Los resultados muestran que cada arquitectura ofrece ventajas complementarias:

- **U-Net** produce segmentaciones globales coherentes, pero no distingue vértebras.
- **Mask R-CNN** logra gran precisión por instancia, pero su costo computacional es elevado.
- **YOLOv8-seg** combina precisión competitiva, tamaño reducido y baja latencia, lo que lo convierte en la opción más adecuada para despliegue en CPU.

A fin de complementar el análisis cuantitativo y las evaluaciones individuales de cada arquitectura, se presenta una comparación cualitativa directa entre U-Net, Mask R-CNN y YOLOv8m-seg utilizando la radiografía S22 (Figura 4). Esta comparación permite observar de manera visual las diferencias en la delimitación de la columna, la definición de contornos y la capacidad para identificar vértebras individuales. Mientras U-Net ofrece una segmentación semántica continua, Mask R-

CNN produce máscaras más precisas pero con mayor costo computacional, y YOLOv8m-seg muestra un balance adecuado entre coherencia anatómica y estabilidad por vértebra. Esta evidencia visual complementa los resultados numéricos y facilita interpretar las fortalezas y limitaciones de cada arquitectura en un caso clínico real.




Fig. 4. Comparación cualitativa de segmentación en la radiografía S22 entre las arquitecturas U-Net, Mask R-CNN y YOLOv8m-seg.

A partir del análisis comparativo, se seleccionaron dos arquitecturas para su integración en la herramienta final: **YOLOv8m-seg**, como opción optimizada para ejecución en CPU, y **Mask R-CNN**, como modelo de referencia con mayor precisión estructural. Estos modelos fueron incorporados en el pipeline de inferencia del sistema con el fin de validar su desempeño operacional en escenarios reales.

Si bien el planteamiento inicial del proyecto contemplaba seleccionar un único modelo para su despliegue final, durante la experimentación se identificó que integrar dos arquitecturas complementarias aportaba ventajas técnicas y operativas relevantes. En particular, **YOLOv8m-seg** mostró el mejor compromiso entre precisión y eficiencia computacional para ejecución en CPU, mientras que **Mask R-CNN** ofreció una segmentación más detallada a nivel de contornos, útil como referencia diagnóstica.

Implementar ambos modelos en la aplicación permitió comparar sus salidas en tiempo real, validar coherencia anatómica desde dos enfoques distintos (*one-stage* vs. *two-stage*) y ofrecer una herramienta más robusta para escenarios clínicos donde la precisión fina o la velocidad puedan ser priorizadas de manera diferente. Esta decisión fortaleció la evaluación del sistema y permitió un análisis más amplio de su comportamiento en entornos con recursos computacionales restringidos.

La siguiente sección describe la arquitectura de despliegue, la integración de los dos modelos en el servicio *API REST* y la herramienta de visualización construida para su evaluación

operativa.

V. IMPLEMENTACIÓN Y DESPLIEGUE DEL SISTEMA: VERTEBRAE SEGMENTATION TOOL

Como complemento a la evaluación cuantitativa de los modelos, se desarrolló una aplicación web denominada **Vertebrae Segmentation Tool**, cuyo propósito es validar la viabilidad operativa del sistema en escenarios reales y evaluar su uso potencial en flujo clínico. Este prototipo constituye un primer *approach* o *Minimum Viable Product* (MVP), orientado a integrar la segmentación automática de la columna vertebral y de cada una de las vértebras individuales en un entorno accesible para profesionales de la salud.

La herramienta permite cargar radiografías AP y seleccionar el modelo de inferencia —YOLO o Mask R-CNN—, habilitando un análisis comparativo directo desde la interfaz. Esta decisión responde a la necesidad de flexibilidad en contextos clínicos diversos: YOLOv8m-seg privilegia rapidez y bajo consumo de recursos, mientras que Mask R-CNN ofrece mayor precisión en contornos complejos. Al incluir ambos modelos, el sistema se adapta tanto a escenarios con hardware limitado como a situaciones donde se prioriza la exactitud anatómica.

1) *Arquitectura general y MLOps*: La solución se diseñó como una arquitectura modular compuesta por un cliente web desarrollado en React y un backend en FastAPI. Siguiendo buenas prácticas de MLOps, ambos componentes fueron contenedorizados mediante Docker, asegurando portabilidad, reproducibilidad y separación clara entre las capas de inferencia, presentación y almacenamiento.

Los modelos entrenados en GPU en Google Colab se almacenaron en un bucket S3 de AWS, desde donde el backend los descarga según demanda. Si bien se evaluó la integración de MLflow para el registro automático de experimentos, métricas y artefactos, restricciones de acceso en el entorno disponible impidieron su implementación. Como alternativa, se adoptó un esquema de versionado manual, en el cual cada modelo entrenado fue almacenado con convenciones de nombrado consistentes, acompañado por su configuración de hiperparámetros, fecha de entrenamiento y métricas asociadas. Este procedimiento garantizó trazabilidad y reproducibilidad suficientes para la etapa de prototipado, permitiendo seleccionar de manera transparente los modelos integrados en la aplicación web final.

El backend se desplegó en Railway utilizando una instancia basada únicamente en CPU. Actualmente, la aplicación se ejecuta sobre 2 vCPUs, con capacidad de escalar hasta 8. En cuanto a la memoria RAM, la aplicación opera con 2GB, escalables hasta 8GB, con el objetivo de validar la operatividad del sistema en entornos sin aceleración por GPU, una condición frecuente en instituciones con recursos computacionales limitados. La imagen Docker del backend se publicó en Docker Hub para facilitar futuros despliegues y la reutilización del servicio.

La Fig. 5 muestra el flujo completo de la arquitectura implementada.




Fig. 5. Arquitectura general de la aplicación web desarrollada. El backend en FastAPI, empaquetado con Docker, carga los modelos almacenados en S3, procesa las inferencias en CPU y expone un servicio API consumido por el cliente web.

2) *Interfaz web y compatibilidad multiplataforma*: La interfaz web permite cargar radiografías, seleccionar el modelo a utilizar y visualizar los resultados mediante una comparación lado a lado entre la imagen original y la segmentada. La aplicación, implementada en React y diseñada para ser ligera y responsiva, está orientada a facilitar su uso en escenarios clínicos, incluso en dispositivos móviles o en centros con infraestructura limitada.

Dado que toda la inferencia ocurre en el backend —ejecutado en CPU— el cliente no requiere capacidad computacional especializada. Esto habilita su utilización desde computadores convencionales, tablets o teléfonos móviles, lo que amplía las posibilidades de adopción, incluyendo consultorios y centros rurales.

La Fig. 6 muestra un ejemplo de la visualización ofrecida por la aplicación.

Además de la visualización gráfica de la segmentación, la herramienta presenta indicadores numéricos asociados al proceso de inferencia, incluyendo el número total de vértebras detectadas, el tiempo de procesamiento en milisegundos y el modelo utilizado para la predicción. Esta funcionalidad permite al usuario inspeccionar la calidad de la inferencia a nivel individual y verificar la completitud de las detecciones, lo cual resulta especialmente útil en contextos clínicos donde se requiere precisión en vértebras específicas para análisis métricos o seguimiento del paciente. La integración de este cuadro de resultados complementa la vista visual y refuerza la utilidad práctica del sistema como herramienta de apoyo diagnóstico.

La aplicación está disponible públicamente en:

<https://vertebrae-frontend.up.railway.app/>

En conjunto, la herramienta web, el backend en CPU, la contenedorización, la arquitectura modular y el despliegue multiplataforma constituyen un prototipo operativo que demuestra que los modelos entrenados pueden emplearse de manera práctica, reproducible y accesible fuera del entorno de desarrollo. Este MVP sienta las bases para una futura herramienta clínica con integración completa de prácticas MLOps.




Fig. 6. Comparación de la radiografía original con su inferencia dentro de la aplicación *Vertebrae Segmentation Tool*.

Results

Detections: 17		Processing Time: 341.91 ms	Model Used: YOLO
#	Vertebra	Confidence	Bounding Box
1	T1	90.7%	(89, 125) - (142, 158)
2	T2	89.5%	(96, 154) - (146, 189)
3	T3	87.7%	(103, 185) - (151, 223)

Fig. 7. Panel de resultados numéricos de la *Vertebrae Segmentation Tool*, donde se muestra el número total de vértebras detectadas, el tiempo de procesamiento y el modelo utilizado para la inferencia.

VI. DISCUSIÓN

Los resultados obtenidos en este trabajo permiten analizar comparativamente el comportamiento de las tres arquitecturas evaluadas —U-Net, Mask R-CNN y YOLOv8m-seg— frente al desafío de segmentar vértebras de manera individual en radiografías AP con escoliosis. En general, los modelos basados en segmentación por instancias (YOLOv8m-seg y Mask R-CNN) demostraron ser más adecuados que los enfoques puramente semánticos (U-Net), lo cual coincide con reportes previos en segmentación de columna donde la distinción vértebra por vértebra resulta crítica para tareas clínicas como la estimación de puntos anatómicos o el cálculo de parámetros angulares [11], [12], [14].

Mask R-CNN presentó las métricas más altas en términos de IoU y Dice, especialmente en vértebras con contornos bien definidos y separaciones claras entre estructuras óseas. Aunque su tamaño (335 MB) y su mayor tiempo de inferencia lo posicionan tradicionalmente como un modelo menos adecuado para despliegues en CPU, en este proyecto se logró optimizarlo y ejecutarlo de forma estable en el backend, demostrando que también puede integrarse en aplicaciones reales sin requerir GPU.

Este resultado es especialmente relevante, pues la literatura suele señalar que las arquitecturas de dos etapas ofrecen alta precisión a costa de una mayor complejidad computacional [12]; sin embargo, los experimentos mostraron que, con un preprocesamiento adecuado, un ajuste cuidadoso del modelo y un entorno de ejecución optimizado, Mask R-CNN puede adaptarse para funcionar de manera estable incluso en CPU. Esto demuestra que, aunque tradicionalmente se considera un modelo pesado, su uso práctico en entornos con recursos limitados es posible cuando se combinan decisiones de ingeniería y MLOps apropiadas.

Por otro lado, YOLOv8m-seg mostró el mejor equilibrio entre precisión, velocidad y eficiencia computacional. Con un Dice promedio por vértebra de 0.74 y un Dice global de columna cercano a 0.90, el modelo alcanzó niveles comparables a los reportados en estudios recientes basados en enfoques de una sola etapa [14]. Sus tiempos de inferencia inferiores a 25 ms y un tamaño de 52 MB respaldan su idoneidad para ejecución en CPU y en aplicaciones web ligeras, convirtiéndolo en un candidato viable para sistemas de apoyo clínico en instituciones con recursos computacionales limitados.

En la aplicación web se permite a los usuarios seleccionar entre exactitud superior (Mask R-CNN) o una respuesta más rápida (YOLOv8m-seg), según las necesidades del caso clínico.

A pesar de estos avances, el desempeño del modelo varía según la región anatómica. Las vértebras torácicas (T1–T12) alcanzaron valores estables de Dice entre 0.74 y 0.82, mientras que la región lumbar baja, especialmente L5, presentó el menor rendimiento Dice ≈ 0.52 . Este patrón también se observa en trabajos previos [8], [14], lo cual sugiere que la complejidad anatómica y el solapamiento pélvico afectan de manera consistente la segmentación en esta región. La limitada representación de L5 en el dataset y la variabilidad anatómica de pacientes con escoliosis agravan esta dificultad. En futuras iteraciones, sería recomendable incrementar el número de muestras lumbares o incorporar mecanismos de atención que permitan resaltar contornos de baja visibilidad.

Respecto a U-Net, aunque no se obtuvieron métricas cuantitativas en el mismo protocolo de evaluación, los resultados visuales muestran que el modelo es capaz de segmentar vértebra por vértebra de manera coherente, especialmente cuando las fronteras anatómicas son claras.

En conjunto, los resultados sugieren que no existe un único modelo “superior”, sino que cada arquitectura ofrece ventajas distintas según el escenario:

- **Mask R-CNN**: mayor precisión en contornos complejos y vértebras lumbares, viable en CPU tras optimización.
- **YOLOv8m-seg**: mejor eficiencia computacional y desempeño general estable, ideal para despliegue ligero.
- **U-Net**: buena coherencia anatómica y flexibilidad en el entrenamiento, aunque sin métricas comparativas.

Estos hallazgos coinciden con trabajos previos que reportan un compromiso entre precisión y eficiencia en tareas de segmentación vertebral [16], [14], y muestran que, con ajustes adecuados, incluso modelos tradicionalmente exigentes pueden adaptarse a entornos con recursos limitados.

Una contribución clave de este trabajo fue evaluar los modelos desde la perspectiva de su despliegue. La construcción del prototipo *Vertebrae Segmentation Tool* permitió validar no solo la precisión de los modelos, sino su comportamiento real en un entorno operativo con CPU. El hecho de que YOLOv8m-seg mantuviera estabilidad y tiempos de respuesta adecuados en condiciones de hardware restringido refuerza su potencial de adopción en escenarios clínicos reales, donde la disponibilidad de GPU es limitada. Asimismo, la posibilidad de seleccionar diferentes modelos desde la aplicación web permite comparar enfoques con prioridades distintas: velocidad (YOLO) frente a precisión en contornos (Mask R-CNN).

Finalmente, al contrastar estos resultados con estudios de referencia, se observa que el rendimiento alcanzado por el modelo propuesto es consistente con valores clínicamente aceptables. Por ejemplo, la literatura reporta errores angulares inferiores a 10° cuando las segmentaciones presentan un Dice superior a 0.70 [14], umbral superado en la mayoría de las vértebras torácicas y lumbares superiores en este trabajo. Este nivel de desempeño sugiere que el sistema tiene el potencial de integrarse en pipelines clínicos orientados al análisis automático de la columna, siempre que se continúe robusteciendo el dataset y afinando las regiones anatómicas más desafiantes.

En conjunto, la discusión evidencia que YOLOv8m-seg representa la alternativa más equilibrada para operacionalizar un sistema de segmentación vertebral en entornos con recursos limitados, mientras que Mask R-CNN ofrece un techo de precisión útil para casos complejos. El prototipo web desarrollado confirma la factibilidad del despliegue y constituye un punto de partida para futuras validaciones clínicas y ampliación del sistema.

VII. CONCLUSIONES Y TRABAJO FUTURO

Este trabajo presentó el diseño, entrenamiento, evaluación y despliegue de un sistema completo de segmentación vértebra por vértebra en radiografías AP con escoliosis, integrando componentes de procesamiento de datos, modelos de aprendizaje profundo y una infraestructura operativa basada en principios de MLOps. Los resultados del estudio muestran que las arquitecturas evaluadas —U-Net, Mask R-CNN y YOLOv8m-seg— presentan fortalezas distintas según el criterio de interés, lo que confirma que la selección del modelo depende del equilibrio entre precisión, eficiencia y restricciones computacionales.

Mask R-CNN obtuvo el mejor desempeño en regiones anatómicamente complejas, especialmente en la zona lumbar, mientras que YOLOv8m-seg demostró el mejor compromiso entre precisión, velocidad y tamaño del modelo, características esenciales para despliegues en CPU. U-Net, aunque sin un análisis métrico comparable, mostró coherencia anatómica robusta y flexibilidad para entrenar con anotaciones parciales, lo que refuerza su utilidad en escenarios donde los datos presentan variabilidad o incompletitud. Estos comportamientos son consistentes con hallazgos reportados en trabajos previos sobre segmentación de columna [16], [14].

Una contribución central de este proyecto fue demostrar la viabilidad de llevar modelos de segmentación profunda a un entorno real mediante una arquitectura modular y ligera. La solución implementada incluyó un backend en FastAPI desplegado en CPU, un frontend responsivo basado en React y contenedorización mediante Docker, lo cual permitió garantizar reproducibilidad, portabilidad y separación clara entre las capas de inferencia, visualización y almacenamiento. Estas decisiones arquitectónicas reflejan buenas prácticas de MLOps aplicadas a un escenario clínico, donde los recursos computacionales suelen ser limitados y la estabilidad operativa es crítica.

La aplicación web desarrollada, *Vertebrae Segmentation Tool*, constituye un primer prototipo funcional que permite cargar radiografías, ejecutar la inferencia utilizando dos modelos complementarios y visualizar tanto las segmentaciones como los indicadores numéricos asociados. Su capacidad para operar sobre dispositivos convencionales y móviles valida la aplicabilidad del sistema en entornos clínicos reales, más allá del laboratorio de desarrollo.

Como líneas de investigación futura, se identifican varias direcciones relevantes. Primero, la ampliación del dataset y la incorporación de más ejemplos de la región lumbar mejorarán la generalización de los modelos. Segundo, la integración de módulos de *post-processing* geométrico y mecanismos de atención podría refinar la segmentación intervertebral. Tercero, la automatización del cálculo del ángulo de Cobb representa un avance natural hacia un sistema de soporte diagnóstico más completo. Finalmente, el establecimiento de un pipeline MLOps completo —incluyendo versionado automático de modelos, monitoreo en producción y pruebas clínicas formales— será fundamental para la transición de esta herramienta hacia un escenario de uso hospitalario o ambulatorio.

En conjunto, los resultados obtenidos demuestran que es posible combinar modelos de segmentación profunda y prácticas modernas de ingeniería para construir soluciones accesibles, eficientes y clínicamente relevantes para el análisis radiográfico de la escoliosis.

REFERENCES

- [1] M. Jamjoom, F. AlKahtani *et al.*, “Deep learning-based automated analysis of scoliosis using anterior–posterior spinal radiographs,” *Spine*, vol. 46, no. 18, pp. 1204–1212, 2021.
- [2] A. Sekuboyina, M. Rempfler *et al.*, “Verse: A vertebra segmentation benchmark challenge,” in *MICCAI Workshop*, 2018, pp. 1–11.
- [3] X. Wang and Y. Zheng, “Automatic vertebrae detection and segmentation from ct images using mask r-cnn,” *Neurocomputing*, vol. 423, pp. 509–518, 2021.
- [4] H. Zhang, P. Wu, and J. Chen, “Vertebra detection and identification in spinal ct using an improved yolov3 framework,” *Computers in Biology and Medicine*, vol. 146, p. 105659, 2022.
- [5] S. Zhou, J. Li, and J. Duncan, “Automatic spine segmentation in lateral x-rays using deep convolutional networks,” *Medical Image Analysis*, vol. 63, p. 101713, 2020.
- [6] F. Galbusera, F. Niemeyer, G. Mastantuoni, and T. Villa, “Automatic vertebra segmentation and identification in spinal radiographs: A computer vision approach,” *Computer Methods and Programs in Biomedicine*, vol. 182, p. 105075, 2019.
- [7] D. Forsberg, E. Sjöblom, and M. Andersson, “Detection and labeling of vertebrae in mr images using deep convolutional neural networks,” *Medical Image Analysis*, vol. 41, pp. 63–73, 2017.
- [8] S. D. S. Group, “Radiographic measurement manual,” *Clinical Guidelines in Spinal Imaging*, 2005, variabilidad inter e intraobservador en mediciones de Cobb.
- [9] X. Xu and Y. Li, “S2vr and boostnet: Deep regression models for spinal deformity,” *Medical Image Analysis*, vol. 60, pp. 101–115, 2020.
- [10] T. Wu, H. Jiang, and Y. Hu, “Automated cobb angle measurement using keypoint detection in spinal radiographs,” *IEEE Access*, vol. 8, pp. 165 538–165 547, 2020.
- [11] O. Ronneberger, P. Fischer, and T. Brox, “U-net: Convolutional networks for biomedical image segmentation,” in *MICCAI*, 2015, pp. 234–241.
- [12] K. He, G. Gkioxari, P. Dollár, and R. Girshick, “Mask r-cnn,” *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 42, no. 2, pp. 386–397, 2018.
- [13] S. Ren, K. He, R. Girshick, and J. Sun, “Faster r-cnn: Towards real-time object detection with region proposal networks,” in *NeurIPS*, 2015.
- [14] Q. Chen, X. Wu, and H. Li, “Instance segmentation of vertebrae in ap radiographs using yolact,” *Computerized Medical Imaging and Graphics*, vol. 98, p. 102103, 2022.
- [15] B. Glocker, D. Zikic, and E. Konukoglu, “Vertebrae localization in spinal ct using random forests and shape constraints,” *Medical Image Analysis*, vol. 17, no. 8, pp. 1295–1305, 2013.
- [16] A. Castro-Molina, J. Gómez, L. Vargas, and A. Cárdenas, “Automated vertebral segmentation in scoliosis radiographs using deep learning,” *Spine Deformity*, vol. 12, no. 1, pp. 45–57, 2024.